

Esquema de entrenamiento de DQN

MountainCar-v0 · la tabla Q se reemplaza por una red neuronal: sin discretizacion, pero con dos maquinas nuevas

1. Estado

Los 2 numeros continuos entran directo a la red: posicion (-1.2 a 0.6) y velocidad (-0.07 a 0.07).
A diferencia de Q-Learning NO se discretiza. No hay bins ni grilla de 400 celdas: la red generaliza entre estados parecidos por si sola.

2. Red Q (QNetwork)

MLP 2 -> 128 -> 128 -> 3, con ReLU en las capas ocultas y SIN activacion en la salida.
Devuelve las 3 Q de una sola pasada, una por accion. Son valores (aqui negativos), no probabilidades: por eso no lleva softmax. 17.283 parametros.

3. Replay Buffer

Cola FIFO de 100.000 transiciones (s, a, r, s', terminated). Cada paso se guarda una y se muestrea un lote de 64 al azar.
Rompe la correlacion temporal: entrenar con pasos consecutivos seria como aprender de un solo episodio repetido. Ademas reutiliza cada experiencia muchas veces.

4. Red Objetivo (Target Net)

Copia congelada de la red Q que solo se re-sincroniza cada 10 episodios. Produce el valor del estado siguiente.
Sin ella la prediccion y el objetivo se moverian a la vez en cada paso: perseguir una meta que se desplaza cada vez que uno avanza.

5. Recompensa y objetivo

-1 por paso, nada mas. Objetivo de Bellman: $r + \gamma * \max Q_target(s') * (1 - terminated)$.
El factor (1 - terminated) anula el futuro solo en estados terminales REALES. Se guarda terminated, no truncated: cortar a los 200 pasos no es el fin del mundo, hay que seguir estimando el futuro.

6. Exploracion correlacionada


Al explorar, el agente se COMPROMETE con la misma accion durante 20-30 pasos, en vez de sortear una nueva cada paso.
Sin esto DQN no aprende nada. El motor es debil: hay que mecerse en rachas largas. Con sorteo por paso, una racha de 20 tiene probabilidad $(1/3)^{20} \sim 3e-10$. Medido: 0 de 300 episodios llegan a la bandera.

La medicion: misma prueba, 300 episodios de exploracion pura, lo unico que cambia es la correlacion temporal			
	Llegan a la bandera	Posicion maxima (media)	Posicion maxima (mejor)
Sorteo por paso	0 / 300	-0.383	-0.163
Rachas de 20-30	38 / 300	0.039	0.537 (meta: 0.5)

Esquema de entrenamiento de DQN · un paso

Izquierda: como se elige la accion (Ejercicio 3). Derecha: como se aprende de ella (Ejercicio 2).

ACTUAR · `select_action`



APRENDER · `_learn`



Sin la rama naranja el agente nunca ve la bandera: todas las recompensas son -1, todos los estados valen lo mismo y la red aprende (correctamente) que nada de lo que hace importa.